模型

1. 模型的一些通用方法：
   - `get_params([deep])`：返回模型的参数。
     - `deep`： 如果为`True`，则可以返回模型参数的子对象。
   - `set_params(**params)`：设置模型的参数。
     - `params`：待设置的关键字参数。
   - `fit(X,y[,sample_weight])`：训练模型。
     - `X`：训练集样本集合。通常是一个`numpy array`，每行代表一个样本，每列代表一个特征。
     - `y`：训练样本的标签集合。它与`X`的每一行相对应。
     - `sample_weight`： 每个样本的权重。它与`X`的每一行相对应。
   - `predict(x)`： 利用模型执行预测。返回一个预测结果序列。
     - `X`：测试集样本集合。通常是一个`numpy array`，每行代表一个样本，每列代表一个特征。
   - `score(X,y[,sample_weight])`：对模型进行评估，返回模型的性能评估结果。
     - `X`：验证集样本集合。通常是一个`numpy array`，每行代表一个样本，每列代表一个特征。
     - `y`：验证集样本的标签集合。它与`X`的每一行相对应。
     - `sample_weight`： 每个样本的权重。它与`X`的每一行相对应。

     > 对于分类模型，其评估的是`accuracy`；对于回归模型，其评估的是`R2`。
     >
     > 如果希望有其它的评估指标，则可以执行`predict()`方法，然后把预测结果、真实标记作为参数来调用一些打分函数即可。

2. 模型的一些通用参数：
   - `n_jobs`：一个正数，指定任务并形时指定的`CPU`数量。

     如果为`-1`则使用所有可用的`CPU`。
   - `verbose`：一个正数。用于开启/关闭迭代中间输出日志功能。
     - 数值越大，则日志越详细。
     - 数值为0或者`None`，表示关闭日志输出。
   - `warm_start`：一个布尔值。如果为`True`，那么使用前一次训练结果继续训练。否则从头开始训练。
   - `max_iter`： 一个整数，指定最大迭代次数。

     如果为`None`则为默认值（不同`solver`的默认值不同）。
   - `random_state`：一个整数或者一个`RandomState`实例，或者`None`。
     - 如果为整数，则它指定了随机数生成器的种子。
     - 如果为`RandomState`实例，则指定了随机数生成器。
     - 如果为`None`，则使用默认的随机数生成器。
3. 对于回归模型，其评估性能的指标为 R^2 。

   假设验证集为 $\mathbb{D}_{validate}$ ， 真实标签记作 $\tilde{y}$,预测值记作 $\hat{y}$ ， 则有：

$$R^2=1-\frac{\sum_{\mathbb{D}_{validate}}(\tilde{y}_i-\hat{y}_i)^2}{(\tilde{y}_i-\bar{y})^2}$$

其中 $\bar{y}$ 为所有真实标记的均值。

根据定义有：

- R^2 不超过 `1` ，但是有可能小于 `0` 。
- R^2 越大，模型的预测性能越好。

一、线性模型

1. 线性模型的一些通用参数：
   - `fit_intercept`：一个布尔值，指定是否需要计算截距项。如果为`False`，那么不会计算截距项。

     当 $\vec{\mathbf{w}}=(w^{(1)},w^{(2)},\cdots,w^{(n)},b)^T=(\vec{\mathbf{w}}^T,b)^T$,$\vec{\mathbf{x}}=(x^{(1)},x^{(2)},\cdots,x^{(n)},1)^T=(\vec{\mathbf{x}}^T,1)^T$ 时， 可以设置 `fit_intercept=False` 。
   - `intercept_scaling`：一个浮点数，用于缩放截距项的正则化项的影响。

     当采用`fit_intercept` 时，相当于人造一个特征出来，该特征恒为 `1` ，其权重为 b 。

     在计算正则化项的时候，该人造特征也被考虑了。为了降低这个人造特征的影响，需要提供 `intercept_scaling` 。
   - `tol`：一个浮点数，指定判断迭代收敛与否的阈值。

1.1 LinearRegression

1. `LinearRegression`是线性回归模型，它的原型为：

```
class sklearn.linear_model.LinearRegression(fit_intercept=True, normalize=False,
copy_X=True, n_jobs=1)
```

   - `fit_intercept`：一个布尔值，指定是否需要计算截距项。
   - `normalize`：一个布尔值。如果为`True`，那么训练样本会在训练之前会被归一化。
   - `copy_X`：一个布尔值。如果为`True`，则会拷贝`X` 。
   - `n_jobs`：一个整数，指定计算并行度。
2. 模型属性：
   - `coef_`：权重向量。
   - `intercept_`：b 值。
3. 模型方法：
   - `fit(X,y[,sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。

1.2 Ridge

1. `Ridge`类实现了岭回归模型。其原型为：

```
class sklearn.linear_model.Ridge(alpha=1.0, fit_intercept=True, normalize=False,
copy_X=True, max_iter=None, tol=0.001, solver='auto', random_state=None)
```

- `alpha`：α 值，用于缓解过拟合。
- `max_iter`： 指定最大迭代次数。
- `tol`：一个浮点数，指定判断迭代收敛与否的阈值。
- `solver`：一个字符串，指定求解最优化问题的算法。可以为：
  - `'auto'`：根据数据集自动选择算法。
  - `'svd'`：使用奇异值分解来计算回归系数。
  - `'cholesky'`：使用 `scipy.linalg.solve` 函数来求解。
  - `'sparse_cg'`：使用 `scipy.sparse.linalg.cg` 函数来求解。
  - `'lsqr'`：使用 `scipy.sparse.linalg.lsqr` 函数求解。

    它运算速度最快，但是可能老版本的 `scipy` 不支持。
  - `'sag'`：使用 `Stochastic Average Gradient descent` 算法求解最优化问题。
- `random_state`：用于设定随机数生成器，它在 `solver=sag` 时使用。
- 其它参数参考 `LinearRegression` 。

2. 模型属性：
   - `coef_`：权重向量。
   - `intercept_`：b 值。
   - `n_iter_`：实际迭代次数。
3. 模型方法： 参考 `LinearRegression` 。
4. 下面的示例给出了不同的 α 值对模型预测能力的影响。
   - 当 α 超过 `1` 之后，随着 α 的增长，预测性能急剧下降。

     这是因为 α 较大时，正则化项 $\alpha||\vec{\mathbf{w}}||_2^2$ 影响较大，模型趋向于简单。
   - 极端情况下当 $\alpha \to \infty$ 时，$\vec{\mathbf{w}} = \vec{\mathbf{0}}$ 从而使得正则化项$\alpha||\vec{\mathbf{w}}||_2^2 = 0$，此时的模型最简单。

     但是预测预测性能非常差，因为对所有的未知样本，模型都预测为同一个常数 b 。

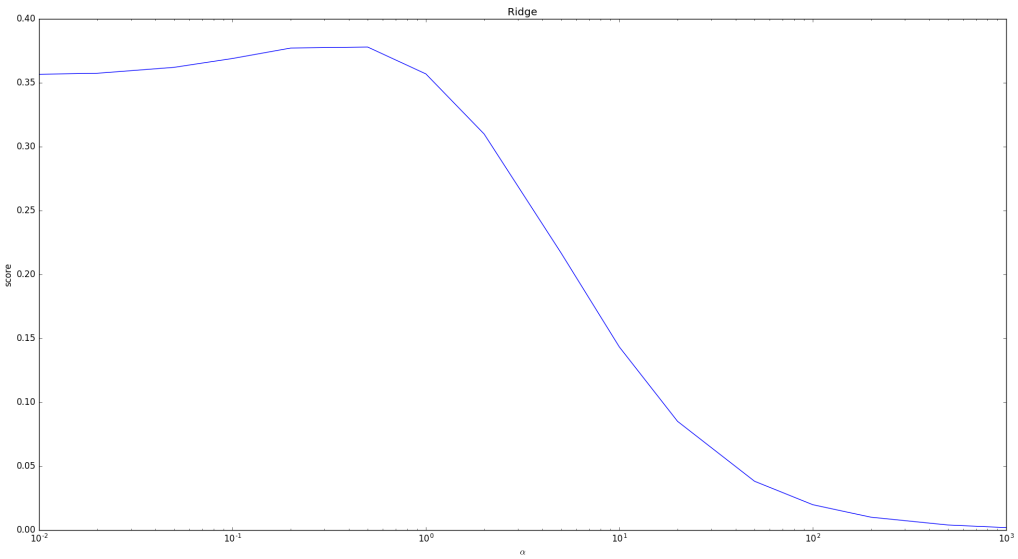

1.3 Lasso

1. `Lasso`类实现了`Lasso`回归模型。其原型为：

```
lass sklearn.linear_model.Lasso(alpha=1.0, fit_intercept=True, normalize=False,
precompute=False, copy_X=True, max_iter=1000, tol=0.0001, warm_start=False,
positive=False, random_state=None, selection='cyclic')
```

   - `alpha`：α 值，用于缓解过拟合。
   - `precompute`：一个布尔值或者一个序列。是否提前计算`Gram`矩阵来加速计算。
   - `warm_start`：是否从头开始训练。
   - `positive`：一个布尔值。如果为`True`，那么强制要求权重向量的分量都为正数。
   - `selection`：一个字符串，可以为`'cyclic'`或者`'random'`。它指定了当每轮迭代的时候，选择权重向量的哪个分量来更新。
     - `'random'`：更新的时候，随机选择权重向量的一个分量来更新
     - `'cyclic'`：更新的时候，从前向后依次选择权重向量的一个分量来更新
   - 其它参数参考`Ridge`。

2. 模型属性：参考`Ridge`。
3. 模型方法： 参考`LinearRegression`。
4. 下面的示例给出了不同的 α 值对模型预测能力的影响。

   当 α 超过`1`之后，随着 α 的增长，预测性能急剧下降。原因同`Ridge`中的分析。

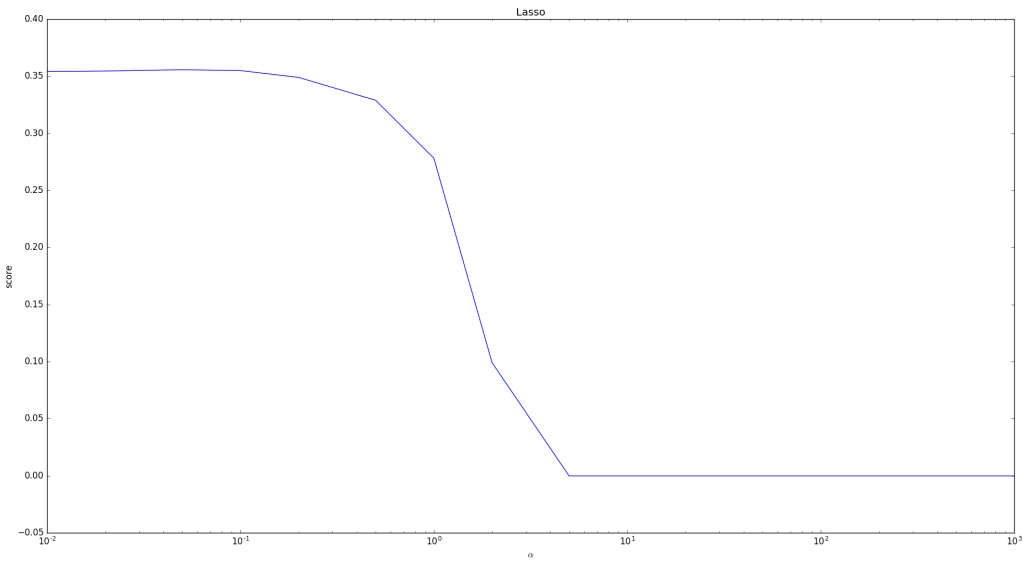

1.4 ElasticNet

1. `ElasticNet`类实现了`ElasticNet`回归模型。其原型为：

```
class sklearn.linear_model.ElasticNet(alpha=1.0, l1_ratio=0.5, fit_intercept=True,
normalize=False, precompute=False, max_iter=1000, copy_X=True, tol=0.0001,
warm_start=False, positive=False, random_state=None, selection='cyclic')
```

- `alpha`：α 值。
- `l1_ratio`：ρ 值。
- 其它参数参考 `Lasso` 。

2. 模型属性：参考 `Lasso` 。
3. 模型方法：参考 `Lasso` 。
4. 下面的示例给出了不同的 α 值和 ρ 值对模型预测能力的影响。
   - 随着 α 的增大，预测性能下降。因为正则化项为：

$$\alpha\rho||\vec{\mathbf{w}}||_1+\frac{\alpha(1-\rho)}{2}||\vec{\mathbf{w}}||_2^2 \quad ,\alpha\geq 0,1\geq\rho\geq 0$$

   - ρ 影响的是性能下降的速度，因为这个参数控制着 $||\vec{\mathbf{w}}||_1$，$||\vec{\mathbf{w}}||_2^2$ 之间的比例 。

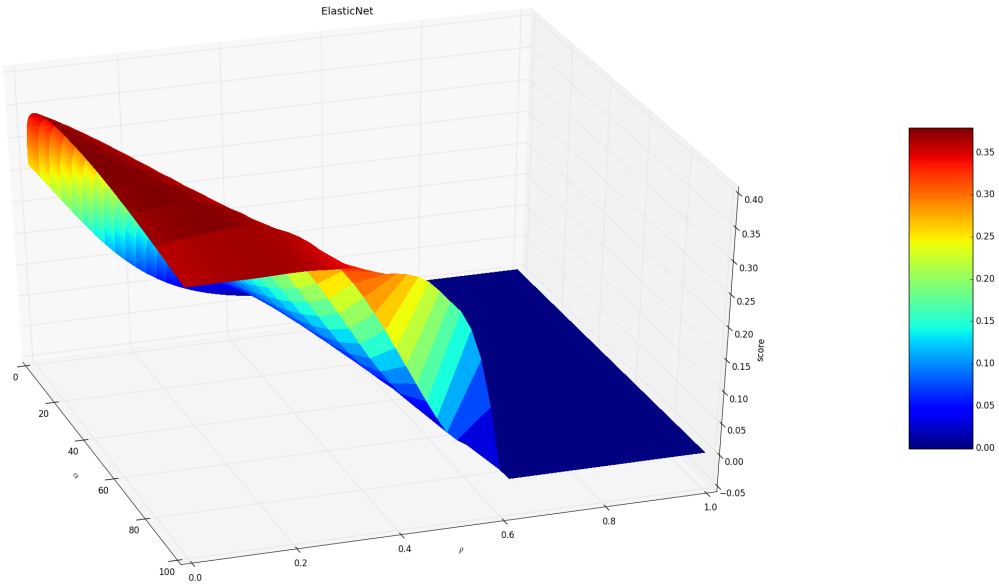

1.4 LogisticRegression

1. `LogisticRegression` 实现了对数几率回归模型。其原型为：

```
class sklearn.linear_model.LogisticRegression(penalty='l2', dual=False, tol=0.0001,
C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None,
random_state=None, solver='liblinear', max_iter=100, multi_class='ovr',
verbose=0, warm_start=False, n_jobs=1)
```

   - `penalty`：一个字符串，指定了正则化策略。
     - 如果为 `'l2'`， 则为 L_2 正则化。
     - 如果为 `'l1'`，则为 L_1 正则化。
   - `dual` ：一个布尔值。
     - 如果为 `True`，则求解对偶形式（只在 `penalty='l2'` 且 `solver='liblinear'` 有对偶形式）。
     - 如果为 `False`，则求解原始形式。
   - `C`：一个浮点数。它指定了罚项系数的倒数。如果它的值越小，则正则化项越大。
   - `class_weight`：一个字典或者字符串 `'balanced'` ，指定每个类别的权重。

        - 如果为字典：则字典给出了每个分类的权重。如`{class_label: weight}`。
        - 如果为字符串`'balanced'`：则每个分类的权重与该分类在样本集中出现的频率成反比。
        - 如果未指定，则每个分类的权重都为`1`。
    - `solver`：一个字符串，指定了求解最优化问题的算法。可以为下列的值：
        - `'newton-cg'`：使用牛顿法。
        - `'lbfgs'`：使用`L-BFGS`拟牛顿法。
        - `'liblinear'`：使用`liblinear`。
        - `'sag'`：使用`Stochastic Average Gradient descent`算法。

      注意：
        - 对于规模小的数据集，`'liblinear'`比较适用；对于规模大的数据集，`'sag'`比较适用。
        - `'newton-cg'`、`'lbfgs'`、`'sag'`只处理`penalty='l2'`的情况。
    - `multi_class`：一个字符串，指定对于多分类问题的策略。可以为：
        - `'ovr'`：采用`one-vs-rest`策略。
        - `'multinomial'`：直接采用多分类`logistic`回归策略。
    - 其它参数参考`ElasticNet`。
2. 模型属性：参考`ElasticNet`。
3. 模型方法：
    - `fit(X,y[,sample_weight])`：训练模型。
    - `predict(X)`：用模型进行预测，返回预测值。
    - `score(X,y[,sample_weight])`：返回模型的预测性能得分。
    - `predict_log_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率的对数值。
    - `predict_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率值。
4. 下面的示例给出了不同的`C`值对模型预测能力的影响。

   `C`是正则化项系数的倒数，它越小则正则化项的权重越大。
    - 随着`C`的增大（即正则化项的减小），`LogisticRegression`的预测准确率上升。
    - 当`C`增大到一定程度（即正则化项减小到一定程度），`LogisticRegression`的预测准确率维持在较高的水准保持不变。

      > 事实上，当`C`太大时，正则化项接近于0，此时容易发生过拟合，预测准确率会下降。

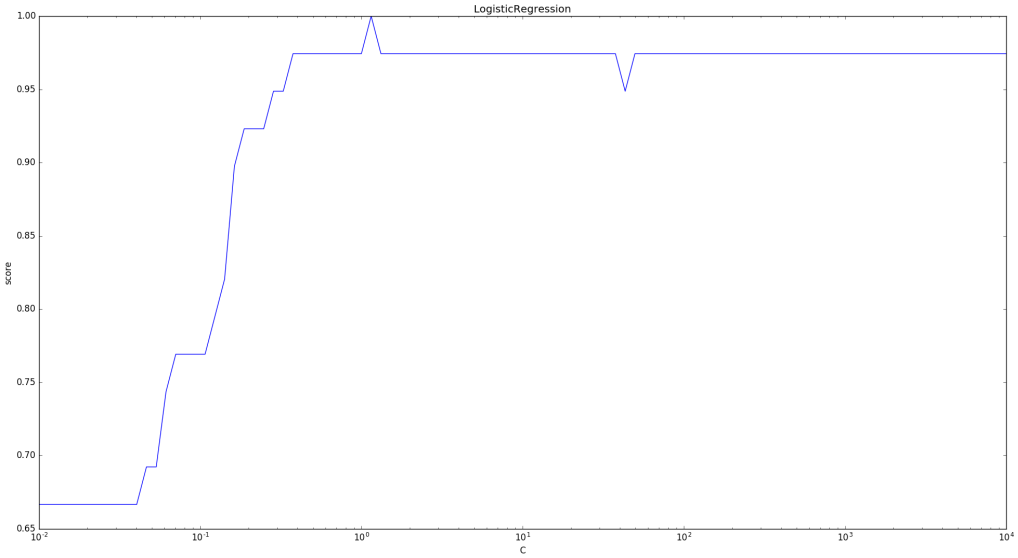

1.5 LinearDiscriminantAnalysis

1. 类`LinearDiscriminantAnalysis`实现了线性判别分析模型。其原型为：

```
class sklearn.discriminant_analysis.LinearDiscriminantAnalysis(solver='svd',
shrinkage=None, priors=None, n_components=None, store_covariance=False, tol=0.0001)
```

   - `solver`：一个字符串，指定求解最优化问题的算法。可以为：
     - `'svd'`：奇异值分解。对于有大规模特征的数据，推荐用这种算法。
     - `'lsqr'`：最小平方差算法，可以结合`shrinkage`参数。
     - `'eigen'`：特征值分解算法，可以结合`shrinkage`参数。
   - `shrinkage`：字符串`'auto'`或者浮点数或者`None`。

     该参数只有在`solver='lsqr'`或者`'eigen'`下才有意义。当矩阵求逆时，它会在对角线上增加一个小的数 λ，防止矩阵为奇异的。其作用相当于正则化。
     - 字符串`'auto'`：根据`Ledoit-Wolf`引理来自动决定 λ 的大小。
     - `None`：不使用`shrinkage`参数。
     - 一个`0`到`1`之间的浮点数：指定 λ 的值。
   - `priors`：一个数组，数组中的元素依次指定了每个类别的先验概率。

     如果为`None`则认为每个类的先验概率都是等可能的。
   - `n_components`：一个整数，指定了数据降维后的维度（该值必须小于`n_classes-1`）。
   - `store_covariance`：一个布尔值。如果为`True`，则需要额外计算每个类别的协方差矩阵 Σ_i。
   - `tol`：一个浮点值。它指定了用于`SVD`算法中评判迭代收敛的阈值。

2. 模型属性：
   - `coef_`：权重向量。
   - `intercept_`：b 值。
   - `covariance_`：一个数组，依次给出了每个类别的协方差矩阵。
   - `means_`：一个数组，依次给出了每个类别的均值向量。

- `xbar_`：给出了整体样本的均值向量。
- `n_iter_`：实际迭代次数。

3. 模型方法： 参考 `LogisticRegression` 。

二、支持向量机

1. `SVM` 的通用参数：
   - `tol`：浮点数，指定终止迭代的阈值。
   - `fit_intercept`：一个布尔值，指定是否需要计算截距项。如果为 `False`，那么不会计算截距项。

     当 $\vec{\mathbf{w}}=(w^{(1)},w^{(2)},\cdots,w^{(n)},b)^T=(\vec{\mathbf{w}}^T,b)^T$,$\vec{\mathbf{x}}=(x^{(1)},x^{(2)},\cdots,x^{(n)},1)^T=(\vec{\mathbf{x}}^T,1)^T$ 时， 可以设置 `fit_intercept=False` 。
   - `intercept_scaling`：一个浮点数，用于缩放截距项的正则化项的影响。

     当采用 `fit_intercept` 时，相当于人造一个特征出来，该特征恒为 `1` ，其权重为 b 。

     在计算正则化项的时候，该人造特征也被考虑了。为了降低这个人造特征的影响，需要提供 `intercept_scaling` 。
   - `class_weight`：一个字典或者字符串 `'balanced'` ，指定每个类别的权重。
     - 如果为字典：则字典给出了每个分类的权重。如 `{class_label: weight}` 。
     - 如果为字符串 `'balanced'`：则每个分类的权重与该分类在样本集中出现的频率成反比。
     - 如果未指定，则每个分类的权重都为 `1` 。

2.1 LinearSVC

1. `LinearSVC` 是根据 `liblinear` 实现的，它可以用于二类分类，也可以用于多类分类问题（此时是根据 `one-vs-rest` 原则来分类）。
2. 线性支持向量机 `LinearSVC`：

```
sklearn.svm.LinearSVC(penalty='l2', loss='squared_hinge', dual=True, tol=0.0001, C=1.0,
multi_class='ovr', fit_intercept=True, intercept_scaling=1, class_weight=None,
verbose=0, random_state=None, max_iter=1000)
```

   - `penalty`：字符串，指定 `'l1'` 或者 `'l2'`，罚项的范数。默认为 `'l2'` （它是标准SVC采用的）。
   - `loss`：一个字符串，表示损失函数。可以为：
     - `'hinge'`：此时为合页损失函数（它是标准 SVM 的损失函数）。
     - `'squared_hinge'`：合页损失函数的平方。
   - `dual`：一个布尔值。如果为 `True`，则解决对偶问题；如果是 `False`,则解决原始问题。当 `n_samples > n_features` 时，倾向于采用 `False` 。
   - `tol` ：一个浮点数，指定终止迭代的阈值。
   - `C`：一个浮点数，罚项系数。
   - `multi_class` ：一个字符串，指定多类分类问题的策略。
     - `'ovr'`：采用 `one-vs-rest` 分类策略。

        - `'crammer_singer'`：多类联合分类，很少用。因为它计算量大，而且精度不会更佳。此时忽略 `loss,penalty,dual` 项。
    - `fit_intercept`：一个布尔值，指定是否需要计算截距项。
    - `intercept_scaling`：一个浮点数，用于缩放截距项的正则化项的影响。
    - `class_weight`： 一个字典或者字符串 `'balanced'` ，指定每个类别的权重。
    - `verbose`：一个正数。用于开启/关闭迭代中间输出日志功能。
    - `random_state`： 指定随机数种子。
    - `max_iter`： 一个整数，指定最大迭代次数。
3. 模型属性：
    - `coef_`：权重向量。
    - `intercept_`：截距值。
4. 模型方法：
    - `fit(X, y)`：训练模型。
    - `predict(X)`：用模型进行预测，返回预测值。
    - `score(X,y[,sample_weight])`：返回模型的预测性能得分。
5. 下面的示例给出了不同的 `C` 值对模型预测能力的影响。

   `C` 衡量了误分类点的重要性，`C` 越大则误分类点越重要。

   为了便于观察将 `x` 轴以对数表示。可以看到当 `C` 较小时，误分类点重要性较低，此时误分类点较多，分类器性能较差。

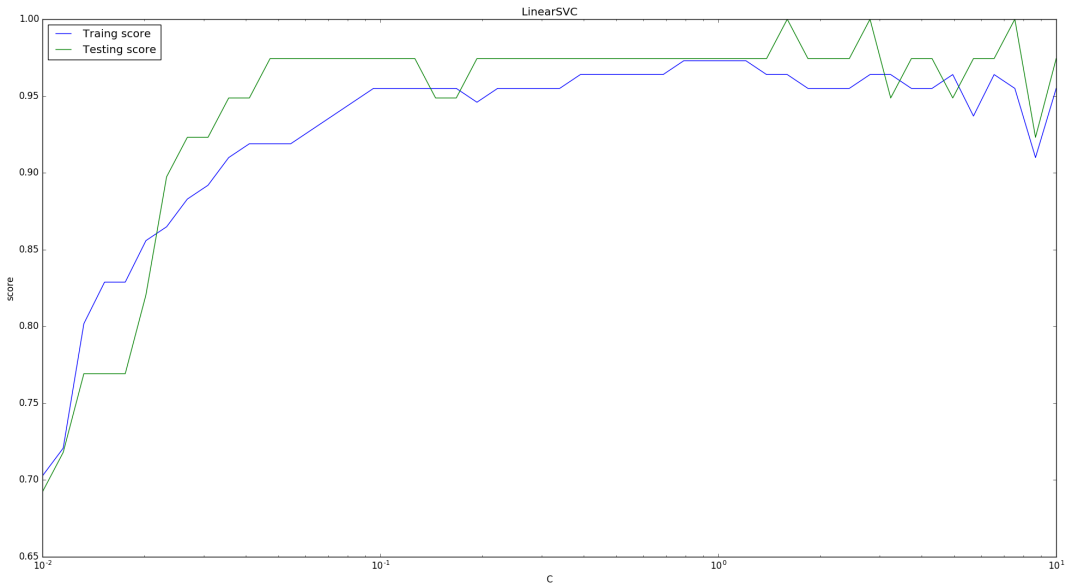

2.2 SVC

1. `SVC` 是根据 `libsvm` 实现的，其训练的时间复杂度是采样点数量的平方。

   它可以用于二类分类，也可以用于多类分类问题（此时默认是根据 `one-vs-rest` 原则来分类）。
2. 支持向量机 `SVC`：

```
sklearn.svm.SVC(C=1.0, kernel='rbf', degree=3, gamma='auto', coef0=0.0, shrinking=True,
probability=False, tol=0.001, cache_size=200, class_weight=None, verbose=False,
max_iter=-1, decision_function_shape=None, random_state=None)
```

- `C`：一个浮点数，罚项系数。
- `kernel`：一个字符串，指定核函数。
  - `'linear'`：线性核：$K(\vec{\mathbf{x}},\vec{\mathbf{z}})=\vec{\mathbf{x}}\cdot\vec{\mathbf{z}}$。
  - `'poly'`：多项式核：$K(\vec{\mathbf{x}},\vec{\mathbf{z}})=(\gamma(\vec{\mathbf{x}}\cdot\vec{\mathbf{z}}+1)+r)^p$。其中：
    - p 由 `degree` 参数决定。
    - γ 由 `gamma` 参数决定。
    - r 由 `coef0` 参数决定。
  - `'rbf'`（默认值）：高斯核函数：$K(\vec{\mathbf{x}},\vec{\mathbf{z}})=\exp(-\gamma||\vec{\mathbf{x}}-\vec{\mathbf{z}}||^2)$。

    其中 γ 由 `gamma` 参数决定。
  - `'sigmoid'`：$K(\vec{\mathbf{x}},\vec{\mathbf{z}})=\tanh(\gamma(\vec{\mathbf{x}}\cdot\vec{\mathbf{z}})+r)$。其中：
    - γ 由 `gamma` 参数决定。
    - `r` 由 `coef0` 参数指定。
  - `'precomputed'`：表示提供了 `kernel matrix`。
  - 或者提供一个可调用对象，该对象用于计算 `kernel matrix`。
- `degree`：一个整数。指定当核函数是多项式核函数时，多项式的系数。对于其他核函数，该参数无效。
- `gamma`：一个浮点数。当核函数是 `'rbf'`，`'poly'`，`'sigmoid'` 时，核函数的系数。如果 `'auto'`，则表示系数为 `1/n_features`。
- `coef0`：浮点数，用于指定核函数中的自由项。只有当核函数是 `'poly'` 和 `'sigmoid'` 是有效。
- `probability`：布尔值。如果为 `True` 则会进行概率估计。它必须在训练之前设置好，且概率估计会拖慢训练速度。
- `shrinking`：布尔值。如果为 `True`，则使用启发式(`shrinking heuristic`)。
- `tol`：浮点数，指定终止迭代的阈值。
- `cache_size`：浮点值，指定了 `kernel cache` 的大小，单位为 MB。
- `class_weight`：指定各类别的权重。
- `decision_function_shape`：为字符串或者 `None`，指定决策函数的形状。
  - `'ovr'`：则使用 `one-vs-rest` 准则。那么决策函数形状是 `(n_samples,n_classes)`。

    此时对每个分类定义了一个二类 `SVM`，一共 `n_classes` 个二类 `SVM`。
  - `'ovo'`：则使用 `one-vs-one` 准测。那么决策函数形状是 `(n_samples, n_classes * (n_classes - 1) / 2)`

    此时对每一对分类直接定义了一个二类 `SVM`，一共 `n_classes * (n_classes - 1) / 2` 个二类 `SVM`。
  - `None`：默认值。采用该值时，目前会使用 `'ovo'`，但是在 `scikit v0.18` 之后切换成 `'ovr'`。
- 其它参数参考 `LinearSVC`。

3. 模型属性：
   - `support_`：一个数组，形状为 `[n_SV]`，给出了支持向量的下标。
   - `support_vectors_`：一个数组，形状为 `[n_SV, n_features]`，给出了支持向量。
   - `n_support_`：一个数组，形状为 `[n_class]`，给出了每一个分类的支持向量的个数。
   - `dual_coef_`：一个数组，形状为 `[n_class-1, n_SV]`。给出了对偶问题中，每个支持向量的系数。
   - `coef_`：一个数组，形状为 `[n_class-1, n_features]`。给出了原始问题中，每个特征的系数。
     - 它只有在 `linear kernel` 中有效。
     - 它是个只读的属性。它是从 `dual_coef_` 和 `support_vectors_` 计算而来。
   - `intercept_`：一个数组，形状为 `[n_class * (n_class-1) / 2]`，给出了决策函数中的常数项。
4. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。
   - `predict_log_proba(X)`：返回一个数组，数组的元素依次是 `X` 预测为各个类别的概率的对数值。
   - `predict_proba(X)`：返回一个数组，数组的元素依次是 `X` 预测为各个类别的概率值。

2.3 NuSVC

1. `NuSVC: Nu-Support Vector Classificatio` 与 `SVC` 相似，但是用一个参数来控制了支持向量的个数。它是基于 `libsvm` 来实现的。
2. `NuSVC` 支持向量机：

```
sklearn.svm.NuSVC(nu=0.5, kernel='rbf', degree=3, gamma='auto', coef0=0.0,
shrinking=True,probability=False, tol=0.001, cache_size=200, class_weight=None,
verbose=False,max_iter=-1, decision_function_shape=None, random_state=None)
```

   - `nu`：一个浮点数，取值范围为 `(0,1]`，默认为0.5。它控制训练误差与支持向量的比值，间接控制了支持向量的个数。
   - 其它参数参考 `SVC`。
3. 模型属性：参考 `SVC`。
4. 模型方法：参考 `SVC`。

2.4 LinearSVR

1. `LinearSVR` 是根据 `liblinear` 实现的。
2. 线性支持向量回归 `LinearSVR`：

```
class sklearn.svm.LinearSVR(epsilon=0.0, tol=0.0001, C=1.0, loss='epsilon_insensitive',
fit_intercept=True, intercept_scaling=1.0, dual=True, verbose=0, random_state=None,
max_iter=1000)
```

   - `epsilon`：一个浮点数，表示 ϵ 值。
   - `loss`：字符串。表示损失函数。可以为：

- `'epsilon_insensitive'`：此时损失函数为 L_ϵ （标准的 `SVR` ）
- `'squared_epsilon_insensitive'`：此时损失函数为 L_ϵ^2

- 其它参数参考 `LinearSVC` 。

3. 模型属性：参考 `LinearSVC` 。
4. 模型方法：参考 `LinearSVC` 。
5. 下面的示例给出了不同的 ϵ 值对模型预测能力的影响。

   为了方便观看将 `x` 轴转换成对数坐标。可以看到预测准确率随着 ϵ 下降。

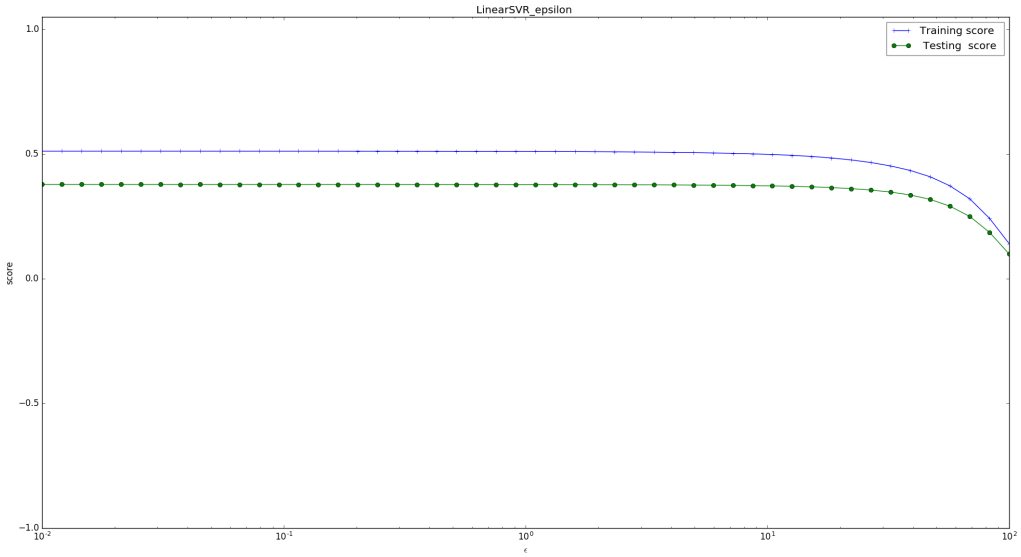

6. 下面的示例给出了不同的 `C` 值对模型预测能力的影响。

   为了方便观看将 `x` 轴转换成对数坐标。可以看到预测准确率随着 C 增大而上升。说明越看重误分类点，则预测的越准确。

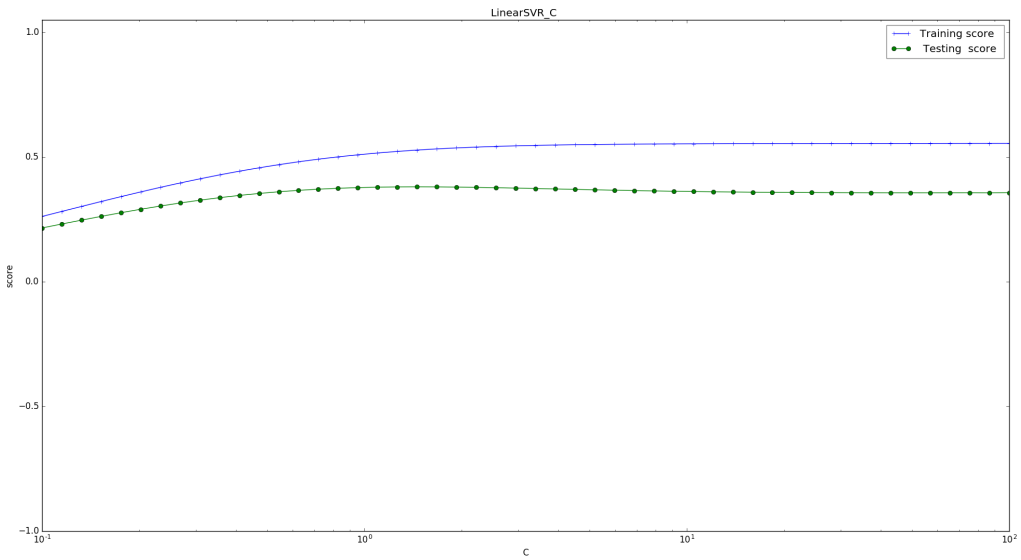

2.5 SVR

1. `SVR` 是根据 `libsvm` 实现的。
2. 支持向量回归 `SVR`：

```
class sklearn.svm.SVR(kernel='rbf', degree=3, gamma='auto', coef0=0.0, tol=0.001, C=1.0,
epsilon=0.1, shrinking=True, cache_size=200, verbose=False, max_iter=-1)
```

   参数：参考 `SVC` 。
3. 模型属性：参考 `SVC` 。
4. 模型方法：参考 `SVC` 。

2.6 NuSVR

1. `NuSVR` 是根据 `libsvm` 实现的。
2. 支持向量回归 `NuSVR`：

```
class sklearn.svm.NuSVR(nu=0.5, C=1.0, kernel='rbf', degree=3, gamma='auto', coef0=0.0,
shrinking=True, tol=0.001, cache_size=200, verbose=False, max_iter=-1)
```

   - `C`：一个浮点数，罚项系数。
   - 其它参数参考 `NuSVC` 。
3. 模型属性：参考 `NuSVC` 。
4. 模型方法：参考 `NuSVC` 。

2.7 OneClassSVM

1. `OneClassSVM` 是根据 `libsvm` 实现的。
2. 支持向量描述 `OneClassSVM`：

```
class sklearn.svm.OneClassSVM(kernel='rbf', degree=3, gamma='auto', coef0=0.0, tol=0.001,
nu=0.5, shrinking=True, cache_size=200, verbose=False, max_iter=-1, random_state=None)
```

   参数：参考 `NuSVC` 。
3. 模型属性：参考 `NuSVC` 。
4. 模型方法：
   - `fit(X[, y, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。每个预测值要么是 `+1` 要么是 `-1` 。

三、贝叶斯模型

1. 在 `scikit` 中有多种不同的朴素贝叶斯分类器。他们的区别就在于它们假设了不同的 $p(x_j \mid y)$ 分布 。

3.1 GaussianNB

1. 高斯贝叶斯分类器`GaussianNB`：它假设特征 x_j 的条件概率分布满足高斯分布：

$$p(x_j \mid y=c_k)=\frac{1}{\sqrt{2\pi\sigma_{k,j}^2}}\exp\left(-\frac{(x_j-\mu_{k,j})^2}{2\sigma_{k,j}^2}\right)$$

其中： $\mu_{k,j}$ 为第 j 个特征的条件概率分布的均值， $\sigma_{k,j}$ 为第 j 个特征的条件概率分布的方差。

2. `GaussianNB` 的原型为：

```
class sklearn.naive_bayes.GaussianNB()
```

3. 模型属性：
   - `class_prior_`：一个数组，形状为`(n_classes,)`，是每个类别的概率 。
   - `class_count_`：一个数组，形状为`(n_classes,)`，是每个类别包含的训练样本数量。
   - `theta_`：一个数组，形状为`(n_classes,n_features)`，是每个类别上，每个特征的均值。
   - `sigma_`：一个数组，形状为`(n_classes,n_features)`，是每个类别上，每个特征的标准差。
4. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `partial_fit(X, y[, classes, sample_weight])`：分批训练模型。

     该方法主要用于大规模数据集的训练。此时可以将大数据集划分成若干个小数据集，然后在这些小数据集上连续调用`partial_fit`方法来训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `predict_log_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率的对数值。
   - `predict_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率值 。
   - `score(X, y[, sample_weight])`：返回模型的预测性能得分。

3.2 MultinomialNB

1. 多项式贝叶斯分类器`MultinomialNB`：它假设特征的条件概率分布满足多项式分布：

$$p(x_j=a_{j,t}\mid y=c_k)=\frac{N_{k,j,t}+\alpha}{N_k+\alpha n}$$

其中：

- $N_k=\sum_{i=1}^{N}I(\tilde{y}_i=c_k)$，表示属于类别 c_k 的样本的数量。
- $N_{k,j,t}=\sum_{i=1}^{N}I(\tilde{y}_i=c_k,x_j=a_{j,t})$，表示属于类别 c_k 且第 j 个特征取值为 $x_j=a_{j,t}$ 的样本的数量。

2. `MultinomialNB` 的原型为：

```
class sklearn.naive_bayes.MultinomialNB(alpha=1.0, fit_prior=True, class_prior=None)
```

- `alpha`：一个浮点数，指定 α 值。
- `fit_prior`：一个布尔值。
  - 如果为`True`，则不去学习 $p(y)$ ，替代以均匀分布。

    - 如果为`False`，则去学习 $p(y)$ 。
  - `class_prior`：一个数组。它指定了每个分类的先验概率 $p(y)$ 。

    如果指定了该参数，则每个分类的先验概率不再从数据集中学得

3. 模型属性：
   - `class_log_prior_`：一个数组对象，形状为`(n_classes,)`。给出了每个类别的调整后的的经验概率分布的对数值。
   - `feature_log_prob_`：一个数组对象，形状为`(n_classes, n_features)`。给出了 $p(x_j \mid y)$ 的经验概率分布的对数值。
   - `class_count_`：一个数组，形状为`(n_classes,)`，是每个类别包含的训练样本数量。
   - `feature_count_`：一个数组，形状为`(n_classes, n_features)`。训练过程中，每个类别每个特征遇到的样本数。
4. 模型方法：参考`GaussianNB`。
5. 下面的示例给出了不同的 α 值对模型预测能力的影响。 运行结果如下。

   为了便于观察将`x`轴设置为对数坐标。可以看到随着 $\alpha > 100$ 之后，随着 α 的增长，预测准确率在下降。

   这是因为，当 $\alpha \to \infty$ 时， $p(x_j = a_{j,t} \mid y = c_k) = \frac{N_{k,j,t}+\alpha}{N_k+\alpha n} \to \frac{1}{n}$ 。即对任何类型的特征、该类型特征的任意取值，出现的概率都是 $\frac{1}{n}$ 。它完全忽略了各个特征之间的差别，也忽略了每个特征内部的分布。

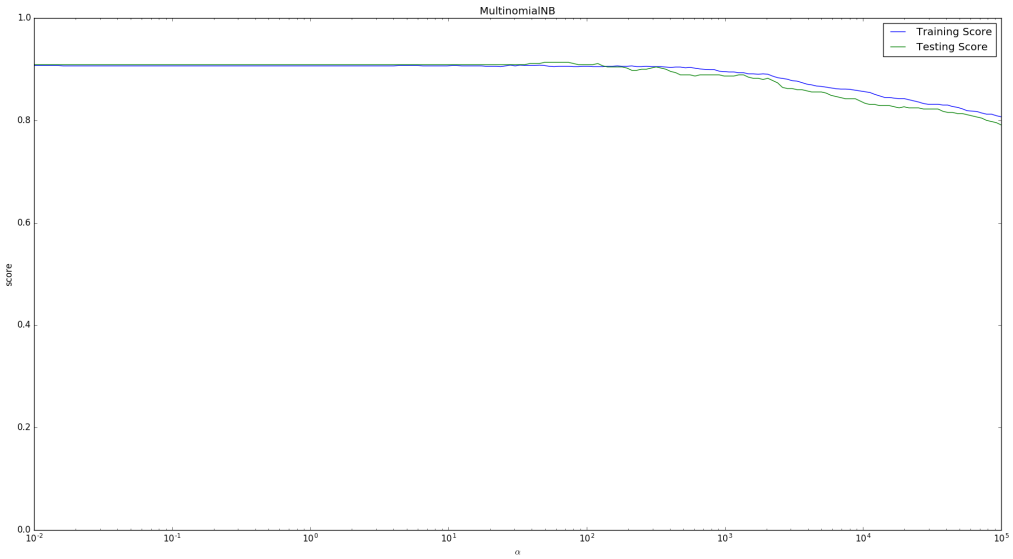

3.3 BernoulliNB

1. 伯努利贝叶斯分类器`BernoulliNB`：它假设特征的条件概率分布满足二项分布：

$$p(x_j \mid y) = p \times x_j + (1-p)(1-x_j)$$

   其中 $p = p(x_j = 1 \mid y)$，且要求特征的取值为 $x_j \in \{0, 1\}$ 。
2. `BernoulliNB`的原型为：

```
class sklearn.naive_bayes.BernoulliNB(alpha=1.0, binarize=0.0, fit_prior=True,
class_prior=None)
```

- `binarize`：一个浮点数或者`None`。
  - 如果为`None`，那么会假定原始数据已经是二元化的。
  - 如果是浮点数，则执行二元化策略：以该数值为界：
    - 特征取值大于它的作为 1 。
    - 特征取值小于它的作为 0 。
- 其它参数参考`MultinomialNB` 。

3. 模型属性：参考`MultinomialNB` 。
4. 模型方法：参考`MultinomialNB` 。

四、决策树

4.1 DecisionTreeRegressor

1. `DecisionTreeRegressor` 是回归决策树，其原型为：

```
class sklearn.tree.DecisionTreeRegressor(criterion='mse', splitter='best',
max_depth=None, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_features=None,random_state=None,
max_leaf_nodes=None, presort=False)
```

- `criterion`：一个字符串，指定切分质量的评价准则。

  默认为`'mse'`，且只支持该字符串，表示均方误差。
- `splitter`：一个字符串，指定切分原则。可以为：
  - `'best'`：表示选择最优的切分。
  - `'random'`：表示随机切分。
- `max_features`：可以为整数、浮点、字符串或者`None`，指定寻找最优拆分时考虑的特征数量。
  - 如果是整数，则每次切分只考虑`max_features`个特征。
  - 如果是浮点数，则每次切分只考虑`max_features * n_features`个特征，`max_features`指定了百分比。
  - 如果是字符串`'sqrt'`，则`max_features`等于`sqrt(n_features)` 。
  - 如果是字符串`'log2'`，则`max_features`等于`log2(n_features)` 。
  - 如果是`None`或者`'auto'`，则`max_features`等于`n_features` 。

  注意：如果已经考虑了`max_features`个特征，但是还没有找到一个有效的切分，那么还会继续寻找下一个特征，直到找到一个有效的切分为止。
- `max_depth`：可以为整数或者`None`，指定树的最大深度。
  - 如果为`None`，则表示树的深度不限。

    分裂子结点，直到每个叶子都是纯的（即：叶结点中所有样本点都属于一个类），或者叶结点中包含小于`min_samples_split`个样点。
  - 如果`max_leaf_nodes`参数非`None`，则忽略此选项。
- `min_samples_split`：为整数，指定每个内部结点包含的最少的样本数。
- `min_samples_leaf`：为整数，指定每个叶结点包含的最少的样本数。

- `min_weight_fraction_leaf`：为浮点数，叶结点中样本的最小权重系数。
- `max_leaf_nodes`：为整数或者`None`，指定最大的叶结点数量。
  - 如果为`None`，此时叶结点数量不限。
  - 如果非`None`，则`max_depth`被忽略。
- `class_weight`：为一个字典、字符串`'balanced'`、或者`None`。它指定了分类的权重。
  - 如果为字典，则权重的形式为：`{class_label:weight}`。
  - 如果为字符串`'balanced'`，则表示分类的权重是样本中各分类出现的频率的反比。
  - 如果为`None`，则每个分类的权重都为1。

  注意：如果提供了`sample_weight`参数（由`fit`方法提供），则这些权重都会乘以`sample_weight`。
- `random_state`：指定随机数种子。
- `presort`：一个布尔值，指定是否要提前排序数据从而加速寻找最优切分的过程。
  - 对于大数据集，设置为`True`会减慢总体的训练过程。
  - 对于一个小数据集或者设定了最大深度的情况下，设置为`True`会加速训练过程。

2. 模型属性：
   - `feature_importances_`：给出了特征的重要程度。该值越高，则该特征越重要。
   - `max_features_`：`max_features`的推断值。
   - `n_features_`：当执行`fit`之后，特征的数量。
   - `n_outputs_`：当执行`fit`之后，输出的数量。
   - `tree_`：一个`Tree`对象，即底层的决策树。
3. 模型方法：
   - `fit(X, y[, sample_weight, check_input, ...])`：训练模型。
   - `predict(X[, check_input])`：用模型进行预测，返回预测值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。

4.2 DecisionTreeClassifier

1. `DecisionTreeClassifier`是分类决策树，其原型为：

```
sklearn.tree.DecisionTreeClassifier(criterion='gini', splitter='best', max_depth=None,
min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0,
max_features=None,random_state=None, max_leaf_nodes=None, class_weight=None,
presort=False)
```

   - `criterion`：一个字符串，指定切分质量的评价准则。可以为：
     - `'gini'`：表示切分时评价准则是`Gini`系数
     - `'entropy'`：表示切分时评价准则是熵
   - 其它参数参考`DecisionTreeRegressor`。
2. 模型属性：
   - `classes_`：分类的标签值。
   - `n_classes_`：给出了分类的数量。
   - 其它属性参考`DecisionTreeRegressor`。
3. 模型方法：

- `fit(X, y[, sample_weight, check_input, ...])`：训练模型。
- `predict(X[, check_input])`：用模型进行预测，返回预测值。
- `predict_log_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率的对数值。
- `predict_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率值。
- `score(X,y[,sample_weight])`：返回模型的预测性能得分。

4.3 决策图

1. 当训练完毕一棵决策树的时候，可以通过`sklearn.tree.export_graphviz(classifier,out_file)`来将决策树转化成`Graphviz`格式的文件。

   > 这里要求安装`Graphviz`程序。`Graphviz`是贝尔实验室开发的一个开源的工具包，用于绘制结构化的图形网络，支持多种格式输出如常用的图片格式、SVG、PDF格式等，且支持`Linux\mid Windows`操作系统。

2. 然后通过`Graphviz`的`dot`工具，在命令行中运行命令`dot.exe -Tpdf F:\mid out -o F:\mid out.pdf`生成`pdf`格式的决策图；或者执行`dot.exe -Tpng F:\mid out -o F:\mid out.png`来生成`png`格式的决策图。

   其中：`-T`选项指定了输出文件的格式，`-o`选项指定了输出文件名。

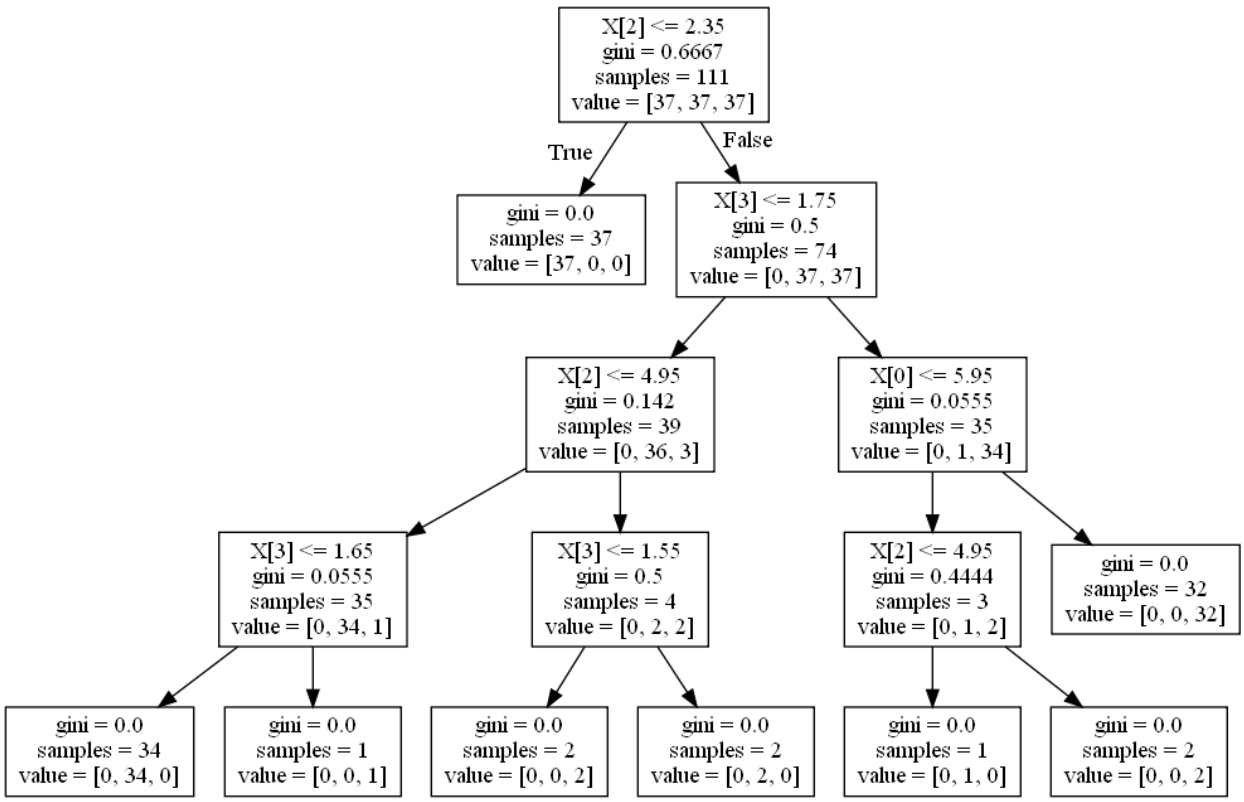

五、KNN

5.1 KNeighborsClassifier

1. `KNeighborsClassifier`是`knn`分类模型，其原型为：

```
sklearn.neighbors.KNeighborsClassifier(n_neighbors=5, weights='uniform',algorithm='auto',
leaf_size=30, p=2, metric='minkowski',metric_params=None, n_jobs=1, **kwargs)
```

- `n_neighbors`：一个整数，指定 k 值。
- `weights`：一字符串或者可调用对象，指定投票权重策略。
  - `'uniform'`：本结点的所有邻居结点的投票权重都相等 。
  - `'distance'`：本结点的所有邻居结点的投票权重与距离成反比。即越近的结点，其投票权重越大。
  - 一个可调用对象：它传入距离的数组，返回同样形状的权重数组。
- `algorithm`：一字符串，指定计算最近邻的算法。可以为：
  - `'ball_tree'`：使用 `BallTree` 算法。
  - `'kd_tree'`：使用 `KDTree` 算法。
  - `'brute'`：使用暴力搜索法。
  - `'auto'`：自动决定最合适的算法。
- `leaf_size`：一个整数，指定 `BallTree` 或者 `KDTree` 叶结点规模。它影响了树的构建和查询速度。
- `metric`：一个字符串，指定距离度量。默认为 `'minkowski'` 距离。
- `p`：一个整数，指定在 `'Minkowski'` 度量上的指数。

  如果 `p=1`，对应于曼哈顿距离； `p=2` 对应于欧拉距离。
- `n_jobs`：并行度。

2. 模型方法：
   - `fit(X,y)`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y)`：返回模型的预测性能得分。
   - `predict_proba(X)`：返回一个数组，数组的元素依次是 `X` 预测为各个类别的概率值。
   - `kneighbors([X, n_neighbors, return_distance])`：返回样本点的 k 近邻点。如果 `return_distance=True`，同时还返回到这些近邻点的距离。
   - `kneighbors_graph([X, n_neighbors, mode])`：返回样本点的 k 近邻点的连接图。

5.2 KNeighborsRegressor

1. `KNeighborsRegressor` 是 `knn` 回归模型，其原型为：

```
sklearn.neighbors.KNeighborsRegressor(n_neighbors=5, weights='uniform', algorithm='auto',
leaf_size=30, p=2, metric='minkowski', metric_params=None, n_jobs=1, **kwargs)
```

参数：参考 `KNeighborsClassifier` 。

2. 模型方法：
   - `fit(X,y)`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y)`：返回模型的预测性能得分。
   - `kneighbors([X, n_neighbors, return_distance])`：返回样本点的 k 近邻点。如果 `return_distance=True`，同时还返回到这些近邻点的距离。

- `kneighbors_graph([X, n_neighbors, mode])`：返回样本点的 k 近邻点的连接图。

六、AdaBoost

6.1 AdaBoostClassifier

1. `AdaBoostClassifier` 是 `AdaBoost` 分类器，其原型为：

```
class sklearn.ensemble.AdaBoostClassifier(base_estimator=None, n_estimators=50,
learning_rate=1.0, algorithm='SAMME.R', random_state=None)
```

   - `base_estimator`：一个基础分类器对象，该基础分类器必须支持带样本权重的学习。默认为 `DecisionTreeClassfier`。
   - `n_estimators`：一个整数，指定基础分类器的数量（默认为50）。

     当然如果训练集已经完美的训练好了，可能算法会提前停止，此时基础分类器数量少于该值。
   - `learning_rate`：一个浮点数，表示学习率，默认为1。它就是下式中的 ν：
     $H_m(\vec{\mathbf{x}}) = H_{m-1}(\vec{\mathbf{x}}) + \nu\alpha_m h_m(\vec{\mathbf{x}})$。
     - 它用于减少每一步的步长，防止步长太大而跨过了极值点。
     - 通常学习率越小，则需要的基础分类器数量会越多，因此在 `learning_rate` 和 `n_estimators` 之间会有所折中。
   - `algorithm`：一个字符串，指定用于多类分类问题的算法，默认为 `'SAMME.R'`。
     - `'SAMME.R'`：使用 `SAMME.R` 算法。基础分类器对象必须支持计算类别的概率。

       通常 `'SAMME.R'` 收敛更快，且误差更小、迭代数量更少。
     - `'SAMME'`：使用 `SAMME` 算法。
   - `random_state`：指定随机数种子。

2. 模型属性：
   - `estimators_`： 所有训练过的基础分类器。
   - `classes_`： 所有的类别标签。
   - `n_classes_`：类别数量。
   - `estimator_weights_`：每个基础分类器的权重。
   - `estimator_errors_`：每个基础分类器的分类误差。
   - `feature_importances_`：每个特征的重要性。
3. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `predict_log_proba(X)`：返回一个数组，数组的元素依次是 `X` 预测为各个类别的概率的对数值。
   - `predict_proba(X)`：返回一个数组，数组的元素依次是 `X` 预测为各个类别的概率值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。
   - `staged_predict(X)`：返回一个数组，数组元素依次是：集成分类器在每一轮迭代结束时的预测值。
   - `staged_predict_proba(X)`：返回一个二维数组，数组元素依次是：集成分类器在每一轮迭代结束时，预测 `X` 为各个类别的概率值。

- `staged_score(X, y[, sample_weight])`：返回一个数组，数组元素依次是：集成分类器在每一轮迭代结束时，该集成分类器的预测性能得分。

6.1 AdaBoostRegressor

1. `AdaBoostRegressor`是`AdaBoost`回归器，其原型为：

```
class sklearn.ensemble.AdaBoostRegressor(base_estimator=None, n_estimators=50,
learning_rate=1.0, loss='linear', random_state=None)
```

   - `base_estimator`：一个基础回归器对象，该基础回归器必须支持带样本权重的学习。默认为`DecisionTreeRegressor`。
   - `loss`：一个字符串。指定了损失函数。可以为：
     - `'linear'`：线性损失函数（默认）。
     - `'square'`：平方损失函数。
     - `'exponential'`：指数损失函数。
   - 其它参数参考`AdaBoostClassifier`。

2. 模型属性：
   - `estimators_`：所有训练过的基础回归器。
   - `estimator_weights_`：每个基础回归器的权重。
   - `estimator_errors_`：每个基础回归器的回归误差。
   - `feature_importances_`：每个特征的重要性。
3. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。
   - `staged_predict(X)`：返回一个数组，数组元素依次是：集成回归器在每一轮迭代结束时的预测值。
   - `staged_score(X, y[, sample_weight])`：返回一个数组，数组元素依次是：集成回归器在每一轮迭代结束时，该集成回归器的预测性能得分。

七、梯度提升树

7.1 GradientBoostingClassifier

1. `GradientBoostingClassifier`是`GBDT`分类模型，其原型为：

```
class sklearn.ensemble.GradientBoostingClassifier(loss='deviance', learning_rate=0.1,
n_estimators=100, subsample=1.0, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_depth=3, init=None, random_state=None,
max_features=None, verbose=0, max_leaf_nodes=None, warm_start=False, presort='auto')
```

   - `loss`：一个字符串，指定损失函数。可以为：
     - `'deviance'`（默认值）：此时损失函数为对数损失函数：$L(\tilde{y},\hat{y})=-\log p(\hat{y})$。
     - `'exponential'`：此时使用指数损失函数。

- `n_estimators`：一个整数，指定基础决策树的数量（默认为100），值越大越好。
- `learning_rate`：一个浮点数，表示学习率，默认为1。它就是下式中的 ν：$H_m(\vec{\mathbf{x}}) = H_{m-1}(\vec{\mathbf{x}}) + \nu\alpha_m h_m(\vec{\mathbf{x}})$ 。
  - 它用于减少每一步的步长，防止步长太大而跨过了极值点。
  - 通常学习率越小，则需要的基础分类器数量会越多，因此在`learning_rate`和`n_estimators`之间会有所折中。
- `max_depth`：一个整数或者`None`，指定了每个基础决策树模型的`max_depth`参数。
  - 调整该参数可以获得最佳性能。
  - 如果`max_leaf_nodes`不是`None`，则忽略本参数。
- `min_samples_split`：一个整数，指定了每个基础决策树模型的`min_samples_split`参数。
- `min_samples_leaf`：一个整数，指定了每个基础决策树模型的`min_samples_leaf`参数。
- `min_weight_fraction_leaf`：一个浮点数，指定了每个基础决策树模型的`min_weight_fraction_leaf`参数。
- `subsample`：一个大于`0`小于等于`1.0`的浮点数，指定了提取原始训练集中多大比例的一个子集用于训练基础决策树。
  - 如果`subsample`小于1.0，则梯度提升决策树模型就是随机梯度提升决策树。

    此时会减少方差但是提高了偏差。
  - 它会影响`n_estimators`参数。
- `max_features`：一个整数或者浮点数或者字符串或者`None`，指定了每个基础决策树模型的`max_features`参数。

  如果`max_features< n_features`，则会减少方差但是提高了偏差。
- `max_leaf_nodes`：为整数或者`None`，指定了每个基础决策树模型的`max_leaf_nodes`参数。
- `init`：一个基础分类器对象或者`None`，该分类器对象用于执行初始的预测。

  如果为`None`，则使用`loss.init_estimator`。
- `verbose`：一个正数。用于开启/关闭迭代中间输出日志功能。
- `warm_start`：一个布尔值。用于指定是否继续使用上一次训练的结果。
- `random_state`：一个随机数种子。
- `presort`：一个布尔值或者`'auto'`。指定了每个基础决策树模型的`presort`参数。

2. 模型属性：
   - `feature_importances_`：每个特征的重要性。
   - `oob_improvement_`：给出训练过程中，每增加一个基础决策树，在测试集上损失函数的改善情况（即：损失函数的减少值）。
   - `train_score_`：给出训练过程中，每增加一个基础决策树，在训练集上的损失函数的值。
   - `init`：初始预测使用的分类器。
   - `estimators_`：所有训练过的基础决策树。
3. 模型方法：
   - `fit(X, y[, sample_weight, monitor])`：训练模型。

     其中`monitor`是一个可调用对象，它在当前迭代过程结束时调用。如果它返回`True`，则训练过程提前终止。

- `predict(X)`：用模型进行预测，返回预测值。
- `predict_log_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率的对数值。
- `predict_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率值。
- `score(X,y[,sample_weight])`：返回模型的预测性能得分。
- `staged_predict(X)`：返回一个数组，数组元素依次是：`GBDT`在每一轮迭代结束时的预测值。
- `staged_predict_proba(X)`：返回一个二维数组，数组元素依次是：`GBDT`在每一轮迭代结束时，预测`X`为各个类别的概率值。
- `staged_score(X, y[, sample_weight])`：返回一个数组，数组元素依次是：`GBDT`在每一轮迭代结束时，该`GBDT`的预测性能得分。

7.2 GradientBoostingRegressor

1. `GradientBoostingRegressor`是`GBRT`回归模型，其原型为：

```
class sklearn.ensemble.GradientBoostingRegressor(loss='ls', learning_rate=0.1,
n_estimators=100, subsample=1.0, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_depth=3, init=None, random_state=None,
max_features=None, alpha=0.9, verbose=0, max_leaf_nodes=None, warm_start=False,
presort='auto')
```

   - `loss`：一个字符串，指定损失函数。可以为：
     - `'ls'`：损失函数为平方损失函数。
     - `'lad'`：损失函数为绝对值损失函数。
     - `'huber'`：损失函数为上述两者的结合，通过`alpha`参数指定比例，该损失函数的定义为：

$$L_{Huber}=\begin{cases}\frac{1}{2}(y-f(x))^2, & \text{if} \quad |y-f(x)|\leq\alpha\\ \alpha|y-f(x)|-\frac{1}{2}\alpha^2, & \text{else}\end{cases}$$

       即误差较小时，采用平方损失；在误差较大时，采用绝对值损失。
     - `'quantile'`：分位数回归（分位数指得是百分之几），通过`alpha`参数指定分位数。
   - `alpha`：一个浮点数，只有当`loss='huber'`或者`loss='quantile'`时才有效。
   - `n_estimators`： 其它参数参考`GradientBoostingClassifier`。
2. 模型属性：
   - `feature_importances_`：每个特征的重要性。
   - `oob_improvement_`：给出训练过程中，每增加一个基础决策树，在测试集上损失函数的改善情况（即：损失函数的减少值）。
   - `train_score_`：给出训练过程中，每增加一个基础决策树，在训练集上的损失函数的值。
   - `init`：初始预测使用的回归器。
   - `estimators_`：所有训练过的基础决策树。
3. 模型方法：
   - `fit(X, y[, sample_weight, monitor])`：训练模型。

其中`monitor`是一个可调用对象，它在当前迭代过程结束时调用。如果它返回`True`，则训练过程提前终止。

- `predict(X)`：用模型进行预测，返回预测值。
- `score(X,y[,sample_weight])`：返回模型的预测性能得分。
- `staged_predict(X)`：返回一个数组，数组元素依次是：`GBRT`在每一轮迭代结束时的预测值。
- `staged_score(X, y[, sample_weight])`：返回一个数组，数组元素依次是：`GBRT`在每一轮迭代结束时，该`GBRT`的预测性能得分。

八、Random Forest

1. `scikit-learn`基于随机森林算法提供了两个模型：
   - `RandomForestClassifier`用于分类问题
   - `RandomForestRegressor`用于回归问题

8.1 RandomForestClassifier

1. `GradientBoostingClassifier`是随机森林分类模型，其原型为：

```
class sklearn.ensemble.RandomForestClassifier(n_estimators=10, criterion='gini',
max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0,
max_features='auto', max_leaf_nodes=None, bootstrap=True, oob_score=False, n_jobs=1,
random_state=None, verbose=0, warm_start=False, class_weight=None)
```

   - `n_estimators`：一个整数，指定了随机森林中决策树的数量.
   - `criterion`：一个字符串，指定了每个决策树的`criterion`参数。
   - `max_features`：一个整数或者浮点数或者字符串或者`None`，指定了每个决策树的`max_features`参数。
   - `max_depth`：一个整数或者`None`，指定了每个决策树的`max_depth`参数。

     如果`max_leaf_nodes`不是`None`，则忽略本参数。
   - `min_samples_split`：一个整数，指定了每个决策树的`min_samples_split`参数。
   - `min_samples_leaf`：一个整数，指定了每个决策树的`min_samples_leaf`参数。
   - `min_weight_fraction_leaf`：一个浮点数，指定了每个决策树的`min_weight_fraction_leaf`参数。
   - `max_leaf_nodes`：为整数或者`None`，指定了每个基础决策树模型的`max_leaf_nodes`参数。
   - `boostrap`：为布尔值。如果为`True`，则使用采样法`bootstrap sampling`来产生决策树的训练数据集。
   - `oob_score`：为布尔值。如果为`True`，则使用包外样本来计算泛化误差。
   - `n_jobs`：指定并行性。
   - `random_state`：指定随机数种子。
   - `verbose`：一个正数。用于开启/关闭迭代中间输出日志功能。
   - `warm_start`：一个布尔值。用于指定是否继续使用上一次训练的结果。

- `class_weight`：一个字典，或者字典的列表，或者字符串`'balanced'`，或者字符串`'balanced_subsample'`，或者`None`：
  - 如果为字典：则字典给出了每个分类的权重，如：`{class_label: weight}`。
  - 如果为字符串`'balanced'`：则每个分类的权重与该分类在样本集中出现的频率成反比。
  - 如果为字符串`'balanced_subsample'`：则样本集为采样法`bootstrap sampling`产生的决策树的训练数据集，每个分类的权重与该分类在采用生成的样本集中出现的频率成反比。
  - 如果为`None`：则每个分类的权重都为`1`。

2. 模型属性：
   - `estimators_`：所有训练过的基础决策树。
   - `classes_`：所有的类别标签。
   - `n_classes_`：类别数量。
   - `n_features_`：训练时使用的特征数量。
   - `n_outputs_`：训练时输出的数量。
   - `feature_importances_`：每个特征的重要性。
   - `oob_score_`：训练数据使用包外估计时的得分。
3. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `predict_log_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率的对数值。
   - `predict_proba(X)`：返回一个数组，数组的元素依次是`X`预测为各个类别的概率值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。

8.2 RandomForestRegressor

1. `RandomForestRegressor`是随机森林回归模型，其原型为：

```
class sklearn.ensemble.RandomForestRegressor(n_estimators=10, criterion='mse',
max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0,
max_features='auto', max_leaf_nodes=None, bootstrap=True, oob_score=False, n_jobs=1,
random_state=None, verbose=0, warm_start=False
```

参数：参考`GradientBoostingClassifier`。

2. 模型属性：
   - `estimators_`：所有训练过的基础决策树。
   - `n_features_`：训练时使用的特征数量。
   - `n_outputs_`：训练时输出的数量。
   - `feature_importances_`：每个特征的重要性。
   - `oob_score_`：训练数据使用包外估计时的得分。
   - `oob_prediction_`：训练数据使用包外估计时的预测值。
3. 模型方法：
   - `fit(X, y[, sample_weight])`：训练模型。
   - `predict(X)`：用模型进行预测，返回预测值。
   - `score(X,y[,sample_weight])`：返回模型的预测性能得分。